

UNIVERSIDAD NACIONAL DE SAN LUIS

Licenciatura en Análisis y Gestión de Datos

Cátedra: Estimación Bayesiana 2026

Equipo Docente: Fernández Elina - Garay Pablo

TRABAJO FINAL: Modelos Computacionales en Inferencia Bayesiana

**Inferencia Variacional aplicada a la Adopción de
Herramientas Digitales en IGT**

Integrantes:

Glaria, Micaela Rocio

Mercado, Gustavo Ariel

Surza, Leandro

Veron, Mirta

1. Descripción de los Modelos Computacionales

La inferencia bayesiana moderna se apoya fuertemente en métodos computacionales para aproximar o muestrear la distribución a posteriori cuando las soluciones analíticas directas no son viables debido a la intratabilidad matemática de la evidencia. A continuación, se describen las técnicas fundamentales en el estado del arte:

Métodos de Monte Carlo por Cadenas de Markov (MCMC)

Los métodos MCMC constituyen el estándar de oro empírico en la estimación bayesiana. Su objetivo es construir una cadena de Markov cuya distribución de equilibrio sea exactamente la distribución a posteriori objetivo. Algoritmos clásicos como *Metropolis-Hastings* o el *Muestreador de Gibbs* permiten explorar el espacio de parámetros mediante caminatas aleatorias o probabilidades condicionales completas. Más recientemente, el algoritmo *No-U-Turn Sampler (NUTS)*, basado en la familia de Monte Carlo Hamiltoniano (HMC), ha mejorado sustancialmente la eficiencia computacional al utilizar gradientes de la distribución para guiar la exploración del espacio paramétrico, evitando las ineficiencias de las caminatas aleatorias puras. A pesar de su exactitud asintótica, MCMC es computacionalmente muy costoso, escalando de manera deficiente ante conjuntos de datos masivos o arquitecturas jerárquicas altamente dimensionales.

Inferencia Variacional (VI)

A diferencia del enfoque estocástico de muestreo de MCMC, la Inferencia Variacional replantea el cálculo de la distribución a posteriori como un problema de optimización matemática. El objetivo de VI es proponer una familia de distribuciones analíticamente tratables y parametrizables (distribuciones variacionales) y ajustar sus parámetros para encontrar la curva que se encuentre más cercana a la verdadera distribución a posteriori. Esta "cercanía" se mide clásicamente minimizando la Divergencia de Kullback-Leibler (KL). Las implementaciones modernas, como la Inferencia Variacional Diferenciable Automática (ADVI), permiten que este proceso se ejecute de manera escalable, veloz y en lotes, haciéndola ideal para aplicaciones de *Machine Learning* y entornos de *Big Data*, sacrificando marginalmente la precisión absoluta en favor de la viabilidad computacional.

Aproximaciones Laplacianas

Las aproximaciones de Laplace ofrecen una solución determinista y extremadamente rápida al aproximar la distribución a posteriori mediante una distribución Normal

(Gaussiana) multivariada. Esta se centra en el modo máximo de la distribución (el estimador Máximo a Posteriori o MAP), y su matriz de covarianza se estima a partir de la inversa de la matriz Hessiana evaluada en dicho punto. Si bien es sumamente eficiente en fases exploratorias, puede presentar sesgos severos si la verdadera distribución a posteriori exhibe fuertes asimetrías, colas pesadas o múltiples modas.

Característica	MCMC (NUTS, Gibbs)	Inferencia Variacional (ADVI)
Enfoque Principal	Muestreo Estocástico	Optimización Matemática
Precisión	Exactitud asintótica garantizada	Aproximada (depende de la familia elegida)
Velocidad y Escalado	Lento, cuello de botella en grandes datos	Muy rápido, adaptable a Minibatching (Big Data)

2. Herramientas y Software

La adopción generalizada de la estadística bayesiana en la última década ha sido impulsada por ecosistemas de software robustos. A nivel industrial y académico, destacan dos entornos principales:

- Ecosistema Python (PyMC, TensorFlow Probability):** PyMC es la biblioteca líder de programación probabilística en Python. Proporciona una abstracción intuitiva para modelar complejas estructuras probabilísticas y delega los cálculos en motores tensoriales de alto rendimiento matemático, soportando de forma nativa la ejecución de NUTS y ADVI. Paralelamente, TensorFlow Probability integra principios bayesianos directamente en el ecosistema de Deep Learning de Google, explotando arquitecturas de hardware acelerado (GPUs) para resolver inferencias variacionales masivas.
- Ecosistema R (Stan, rstan, brms):** Stan constituye el motor inferencial en C++ más respetado del mundo estadístico, empleando la vanguardia del Monte Carlo Hamiltoniano. Mediante interfaces como *rstan*, los usuarios conectan R con C++; mientras que bibliotecas de alto nivel como *brms* permiten especificar sofisticados

modelos jerárquicos bayesianos utilizando una sintaxis de fórmulas lineales (al estilo clásico de Jme4), democratizando el acceso a MCMC sin la necesidad de programar directamente las probabilidades.

3. Casos de Aplicación

La potencia computacional bayesiana ha permeado múltiples áreas aplicadas:

1. **Ciencia de Datos y Experiencia de Usuario:** Ejecución de pruebas A/B bayesianas en desarrollo web. A diferencia del valor-p clásico, devuelven una distribución de probabilidad explícita sobre el "levantamiento" (uplift) esperado, facilitando decisiones productivas bajo incertidumbre de manera intuitiva.
2. **Economía, Finanzas y Riesgo:** Estimación de volatilidad en series temporales financieras y ajuste de parámetros dinámicos en modelos macroeconómicos de equilibrio general (DSGE), integrando conocimiento experto como previas.
3. **Gobernanza y Modernización de Sistemas Públicos:** Modelización probabilística aplicada a la asignación de recursos estatales, tiempos de resolución de expedientes legales y proyecciones de adopción tecnológica ciudadana en infraestructuras gubernamentales.

4. Implementación Práctica: Caso Proyecto IGT

Para la implementación práctica, este equipo ha diseñado un modelo inferencial enfocado en el despliegue del **Proyecto IGT (Inteligencia y Gobernanza Técnica)**. En el marco de la modernización del portal de la Función Judicial, se implementará un nuevo buscador avanzado de jurisprudencia. Nuestro objetivo es estimar la verdadera **tasa de adopción de la herramienta** (parámetro θ), entendida como la probabilidad de que un integrante del poder judicial o profesional del derecho utilice el módulo al ingresar a la plataforma.

Estructura del Modelo Bayesiano

Debido al volumen esperado de interacciones concurrentes con la base de datos y los servidores web, hemos seleccionado **Inferencia Variacional (ADVI)** con PyMC para nuestra arquitectura.

- **La Verosimilitud (Datos Observables):** La métrica a registrar es binaria (usó o no usó la herramienta). Así, la cantidad total de adopciones Y sobre un universo de N accesos a la plataforma se modeliza formalmente mediante una distribución

Binomial:

$Y \sim \text{Binomial}(N, \theta)$

- **Distribución a Priori:** Históricamente, la adopción de nuevas rutinas informáticas por parte de los operadores del sistema judicial exige una curva de aprendizaje. No esperamos una adopción masiva instantánea. Modelaremos este conocimiento previo utilizando una distribución Beta moderadamente informada y sesgada hacia una tasa de adopción conservadora, asignando un peso análogo a observar empíricamente 2 éxitos en 12 intentos iniciales imaginarios:

$\theta \sim \text{Beta}(2, 10)$

Actualización y Resultados (Proyección): Al inyectar la telemetría mensual (las N visitas reales y Y consultas de jurisprudencia) al algoritmo variacional, la distribución a posteriori revelará la ubicación más probable de la adopción real θ del IGT-Rioja. A partir de esto, extraeremos el Intervalo de Alta Densidad (HDI) del 94% y la media a posteriori para entregar a los directivos un reporte probabilístico exento de falsas certezas categóricas, garantizando un despliegue técnico informado.

***Nota:** El código funcional en Python con PyMC, donde se definen estas variables estocásticas, se realiza la aproximación variacional, se extraen las trazas y se plotean los gráficos de convergencia, se incluye íntegramente documentado en el archivo adjunto requerido por la cátedra.*

5. Bibliografía

- Blei, D. M., Kucukelbir, A., & McAuliffe, J. D. (2017). *Variational Inference: A Review for Statisticians*. Journal of the American Statistical Association, 112(518), 859-877.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3rd ed.). CRC Press.
- McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan* (2nd ed.). CRC Press.
- Salvatier, J., Wiecki, T. V., & Fonnesbeck, C. (2016). *Probabilistic programming in Python using PyMC3*. PeerJ Computer Science, 2, e55.
- Documentación interna y planificación técnica del Proyecto IGT, Función Judicial de La Rioja (2026).
- Material y apuntes teóricos de la cátedra "Estimación Bayesiana" (2026). Licenciatura en Análisis y Gestión de Datos, Universidad Nacional de San Luis. Equipo docente: Fernández Elina y Garay Pablo.