

UNIVERSIDAD NACIONAL DE SAN LUIS
Facultad de Cs. Físico Matemáticas y Naturales
Facultad de Cs. Económicas, Jurídicas y Sociales



TRABAJO FINAL: Modelos Computacionales en
Inferencia Bayesiana de la Licenciatura en Análisis y
Gestión de Datos

*Inferencia Variacional aplicada a la Adopción de
Herramientas Digitales en IGT*

Glaria, Micaela Rocio
Mercado, Gustavo Ariel
Verón, Mirta Celia

Cátedra: Estimación Bayesiana 2026
Equipo Docente: Fernández Elina - Garay Pablo

Introducción

En el marco de la modernización de los sistemas públicos y la gobernanza digital, la Función Judicial de La Rioja ha iniciado el despliegue del Proyecto IGT (Inteligencia y Gobernanza Técnica). Uno de los pilares de esta transformación es la implementación de un nuevo buscador avanzado de jurisprudencia en su portal web oficial, diseñado para optimizar los tiempos de resolución y facilitar el acceso a la información para los operadores jurídicos.

Sin embargo, la incorporación de nuevas tecnologías en entornos burocráticos tradicionales suele enfrentarse a curvas de aprendizaje pronunciadas y fenómenos de resistencia institucional. En este contexto, la toma de decisiones basada exclusivamente en métricas e indicadores puntuales del enfoque frecuentista tradicional resulta insuficiente, ya que no permite cuantificar la incertidumbre intrínseca de los procesos de adopción en sus fases iniciales.

La estadística bayesiana ofrece un marco metodológico robusto para abordar esta problemática. A diferencia del análisis clásico, el paradigma bayesiano permite integrar el conocimiento experto o histórico del comportamiento institucional (distribución a priori) con los datos empíricos de telemetría capturados en tiempo real (función de verosimilitud). Este enfoque transforma los parámetros fijos en variables aleatorias, permitiendo actualizar nuestras creencias de forma dinámica a medida que ingresa nueva evidencia del sistema.

1. Descripción de los Modelos Computacionales

La inferencia bayesiana moderna se apoya fuertemente en métodos computacionales para aproximar o muestrear la distribución a posteriori cuando las soluciones analíticas directas no son viables debido a la intratabilidad matemática de la evidencia. A continuación, se describen las técnicas fundamentales en el estado del arte.

1.1. Métodos de Monte Carlo por Cadenas de Markov (MCMC)

Los métodos MCMC constituyen el estándar de oro empírico en la estimación bayesiana. Su objetivo es construir una cadena de Markov cuya distribución de equilibrio sea exactamente la distribución a posteriori objetivo. Algoritmos clásicos como *Metropolis-Hastings* o el *Muestreador de Gibbs* permiten explorar el espacio de parámetros mediante caminatas aleatorias o probabilidades condicionales completas. Más recientemente, el algoritmo *No-U-Turn Sampler (NUTS)*, basado en la familia de Monte Carlo Hamiltoniano (HMC), ha mejorado sustancialmente la eficiencia computacional al utilizar gradientes de la distribución para guiar la exploración del espacio paramétrico, evitando las ineficiencias de las caminatas aleatorias puras. A pesar de su exactitud asintótica, MCMC es computacionalmente

muy costoso, escalando de manera deficiente ante conjuntos de datos masivos o arquitecturas jerárquicas altamente dimensionales.

1.2. Inferencia Variacional (VI)

A diferencia del enfoque estocástico de muestreo de MCMC, la Inferencia Variacional replantea el cálculo de la distribución a posteriori como un problema de optimización matemática. El objetivo de VI es proponer una familia de distribuciones analíticamente tratables y parametrizables (distribuciones variacionales) y ajustar sus parámetros para encontrar la curva que se encuentre más cercana a la verdadera distribución a posteriori. Esta "cercanía" se mide clásicamente minimizando la Divergencia de Kullback-Leibler (KL). Las implementaciones modernas, como la Inferencia Variacional Diferenciable Automática (ADVI), permiten que este proceso se ejecute de manera escalable, veloz y en lotes, haciéndola ideal para aplicaciones de *Machine Learning* y entornos de *Big Data*, sacrificando marginalmente la precisión absoluta en favor de la viabilidad computacional.

1.3. Aproximaciones Laplacianas

Las aproximaciones de Laplace ofrecen una solución determinista y extremadamente rápida al aproximar la distribución a posteriori mediante una distribución Normal (Gaussiana) multivariada. Esta se centra en el modo máximo de la distribución (el estimador Máximo a Posteriori o MAP), y su matriz de covarianza se estima a partir de la inversa de la matriz Hessiana evaluada en dicho punto. Si bien es sumamente eficiente en fases exploratorias, puede presentar sesgos severos si la verdadera distribución a posteriori exhibe fuertes asimetrías, colas pesadas o múltiples modas.

Característica	MCMC (NUTS, Gibbs)	Inferencia Variacional (ADVI)
Enfoque Principal	Muestreo Estocástico	Optimización Matemática
Precisión	Exactitud asintótica garantizada	Aproximada (depende de la familia elegida)
Velocidad y Escalado	Lento, cuello de botella en grandes datos	Muy rápido, adaptable a Minibatching (Big Data)

2. Herramientas y Software

La adopción generalizada de la estadística bayesiana en la última década ha sido impulsada por ecosistemas de software robustos. A nivel industrial y académico, destacan dos entornos principales:

2.1. Ecosistema Python (PyMC, TensorFlow Probability): PyMC es la biblioteca líder de programación probabilística en Python. Proporciona una abstracción intuitiva para modelar complejas estructuras probabilísticas y delega los cálculos en motores tensoriales de alto rendimiento matemático, soportando de forma nativa la ejecución de NUTS y ADVI. Paralelamente, TensorFlow Probability integra principios bayesianos directamente en el ecosistema de Deep Learning de Google, explotando arquitecturas de hardware acelerado (GPUs) para resolver inferencias variacionales masivas.

2.2. Ecosistema R (Stan, rstan, brms): Stan constituye el motor inferencial en C++ más respetado del mundo estadístico, empleando la vanguardia del Monte Carlo Hamiltoniano. Mediante interfaces como *rstan*, los usuarios conectan R con C++; mientras que bibliotecas de alto nivel como *brms* permiten especificar sofisticados modelos jerárquicos bayesianos utilizando una sintaxis de fórmulas lineales (al estilo clásico de lme4), democratizando el acceso a MCMC sin la necesidad de programar directamente las probabilidades.

3. Casos de Aplicación

La potencia computacional bayesiana ha permeado múltiples áreas aplicadas:

- **Ciencia de Datos y Experiencia de Usuario:** Ejecución de pruebas A/B bayesianas en desarrollo web. A diferencia del valor-p clásico, devuelven una distribución de probabilidad explícita sobre el "levantamiento" (uplift) esperado, facilitando decisiones productivas bajo incertidumbre de manera intuitiva.
- **Economía, Finanzas y Riesgo:** Estimación de volatilidad en series temporales financieras y ajuste de parámetros dinámicos en modelos macroeconómicos de equilibrio general (DSGE), integrando conocimiento experto como previas.
- **Gobernanza y Modernización de Sistemas Públicos:** Modelización probabilística aplicada a la asignación de recursos estatales, tiempos de resolución de expedientes legales y proyecciones de adopción tecnológica ciudadana en infraestructuras gubernamentales.

4. Implementación Práctica: Caso Proyecto IGT

Para la implementación práctica, este equipo ha diseñado un modelo inferencial enfocado en el despliegue del Proyecto IGT (Inteligencia y Gobernanza Técnica). En el marco de la modernización del portal de la Función Judicial, se implementará un nuevo buscador avanzado de jurisprudencia. Nuestro objetivo es estimar la verdadera tasa de adopción de la herramienta (parámetro θ), entendida como la probabilidad de que un integrante del poder judicial o profesional del derecho utilice el módulo al ingresar a la plataforma.

4.1. Estructura del Modelo Bayesiano

Debido al volumen esperado de interacciones concurrentes con la base de datos y los servidores web, hemos seleccionado Inferencia Variacional (ADVI) con PyMC para nuestra arquitectura:

- **La Verosimilitud (Datos Observables):** La métrica a registrar es binaria (usó o no usó la herramienta). Así, la cantidad total de adopciones Y sobre un universo de N accesos a la plataforma se modeliza formalmente mediante una distribución Binomial:
 $Y \sim \text{Binomial}(N, \theta)$
- **Distribución a Priori:** Históricamente, la adopción de nuevas rutinas informáticas por parte de los operadores del sistema judicial exige una curva de aprendizaje. No esperamos una adopción masiva instantánea. Modelaremos este conocimiento previo utilizando una distribución Beta moderadamente informada y sesgada hacia una tasa de adopción conservadora, asignando un peso análogo a observar empíricamente 2 éxitos en 12 intentos iniciales imaginarios:
 $\theta \sim \text{Beta}(2, 10)$

4.2. Análisis Inferencial y Procesamiento de Telemetría

La inyección de la telemetría mensual, compuesta por el volumen de visitas reales (N) y las consultas de jurisprudencia efectivas (Y), en el algoritmo de Inferencia Variacional permite actualizar probabilísticamente la ubicación del parámetro θ para el Proyecto IGT. A partir de este proceso de optimización, se extrae la media a posteriori y el Intervalo de Máxima Densidad (HDI) al 94%. Este enfoque provee a la dirección de la Función Judicial un reporte probabilístico riguroso que cuantifica con precisión la incertidumbre y evita las falsas certezas categóricas de la estadística tradicional, garantizando un diagnóstico técnico informado para la toma de decisiones.

El entorno de programación probabilística en Python, desarrollado mediante la biblioteca PyMC, se encarga de la definición de las variables estocásticas, la ejecución de la aproximación variacional, la validación de las trazas y la generación de las

visualizaciones analíticas de convergencia. El script funcional correspondiente se encuentra íntegramente documentado y estructurado en el archivo de código fuente adjunto.


4.3. Análisis de Resultados por Escenarios de Gestión

Para evaluar el comportamiento del indicador y dotar a la toma de decisiones de una perspectiva probabilística que mitigue el riesgo, el script procesó tres simulaciones analíticas diferenciadas:


4.3.1. Escenario 1: Lanzamiento Base (Mes 1)

Este escenario representa el despliegue inicial de la herramienta en producción, sin intervenciones de capacitación previa, registrando una telemetría de $N = 2500$ visitas totales y $Y = 415$ consultas de jurisprudencia efectivas.

Diagnóstico de Convergencia (ELBO): El gráfico de evolución de la función de pérdida variacional (ELBO) muestra un descenso abrupto en las primeras iteraciones del optimizador *Adam*, alcanzando una meseta horizontal completamente estable antes de las 10.000 iteraciones. Esto garantiza que la aproximación matemática realizada en PyMC es numéricamente confiable.




Estimación de la Posteriori: La distribución posterior adopta una geometría gaussiana simétrica y angosta, arrojando una media a posteriori de 0,165 y un Intervalo de Credibilidad (HDI) del 94% confinado entre el 15,3% y el 17,8%. En términos de gestión, este resultado convalida con alta precisión las expectativas de la priori institucional para la fase temprana de lanzamiento.



4.3.2. Escenario 2: Resistencia Institucional (Mes 2)


Este escenario simula una fase crítica de alta demanda y pico de trabajo en los tribunales ($N = 5000$ visitas generales), pero donde se experimenta un estancamiento en el uso efectivo de la nueva tecnología, registrando únicamente $Y = 500$ consultas.

Diagnóstico de Convergencia (ELBO): Al igual que en el caso anterior, el gráfico de pérdida ELBO válida una convergencia óptima y plana, asegurando la estabilidad del algoritmo variacional bajo mayores volúmenes de datos.



Estimación de la Posteriori: El histograma de densidad probabilística se desplaza notablemente hacia la izquierda, concentrando la masa de probabilidad


en valores inferiores. El modelo estima una media a posteriori de 0,101 y un Intervalo de Credibilidad (HDI) del 94% ubicado entre el 9,4% y el 10,9%. La alta concentración de la muestra (5.000 registros) dota al modelo de una gran precisión, estrechando el intervalo y alertando formalmente a los directivos sobre un estancamiento en la adopción del sistema.




4.3.3. Escenario 3: Éxito Post-Capacitación (Mes 3)

Este escenario modela el impacto directo de políticas activas de modernización, simulando el comportamiento del portal tras la ejecución de jornadas intensivas de capacitación técnica dirigidas a los operadores de la Función Judicial. La telemetría registra $N = 3000$ visitas totales y un incremento masivo de consultas, alcanzando los $Y = 850$ éxitos.

Diagnóstico de Convergencia (ELBO): La cota inferior de la evidencia vuelve a exhibir un comportamiento de optimización ideal, estabilizándose de forma constante a lo largo de las 30.000 iteraciones del gradiente estocástico, confirmando la solidez computacional de la arquitectura propuesta en PyMC.



Estimación de la Posteriori: La fuerza de los datos empíricos observados en este mes es tan contundente que logra vencer de forma absoluta la resistencia de la priori conservadora inicial. La campana de densidad se desplaza con fuerza hacia la derecha de la escala paramétrica, fijando la media a posteriori en 0,285.



Intervalo de Alta Densidad (HDI): El reporte bayesiano entrega un Intervalo de Credibilidad del 94% que se sitúa estrictamente entre el 27% y el 30,2%. Esto le permite concluir científicamente al equipo que existe un 94% de probabilidad real de que la tasa de adopción real del Buscador IGT se encuentre por encima del 27% tras la capacitación, demostrando la efectividad empírica de la intervención institucional.

4.3.4 Resumen Comparativo de Parámetros Estimados

Para sintetizar el comportamiento inferencial y facilitar la presentación de la telemetría

ante la dirección de la Función Judicial de La Rioja, se consolidan las estimaciones obtenidas mediante el algoritmo variacional ADVI en la siguiente matriz analítica:

Escenario de Simulación Analizada	Volumen Muestral (N)	Consultas Exitosas (Y)	Tasa Frecuentista (Y/N)
1. Lanzamiento Base	2500	415	16.6%
2. Resistencia	5000	500	10%
3. Éxito Post-Capacitación	3000	850	28.33%

Anexo: Material Complementario

Como complemento práctico al análisis inferencial desarrollado en este informe, y conforme a los requerimientos metodológicos de la cátedra, se adjuntan los recursos técnicos y el entorno probabilístico implementados por el equipo. Los archivos fuentes correspondientes al script de Python (desarrollado bajo la arquitectura PyMC) y las simulaciones del panel interactivo (dashboard) se encuentran completamente documentados y disponibles para su revisión a través de los siguientes enlaces:

- Para auditar el código o descargarlo en .ZIP:
https://github.com/gustavonegh/igt_bayesiano
- Para ver el Dashboard directo en una pestaña:
https://gustavonegh.github.io/igt_bayesiano/

Conclusión

El desarrollo de este trabajo final permitió validar la utilidad práctica de la estadística bayesiana computacional para evaluar la transformación digital en el sector público, tomando como eje el Proyecto IGT de la Función Judicial de La Rioja. En el plano metodológico, la implementación de la Inferencia Variacional Automática (ADVI) mediante PyMC demostró ser una alternativa sumamente eficiente frente a los métodos tradicionales de MCMC. La rápida y constante convergencia de la cota inferior de la evidencia (ELBO) observada en las simulaciones confirma que es posible modelar y procesar grandes volúmenes de telemetría web de forma óptima sin comprometer la

infraestructura técnica de la organización.

En cuanto a la gestión institucional, el análisis comparativo de los escenarios evidenció la flexibilidad del enfoque bayesiano para actualizar la inercia de la priori conservadora inicial: Beta(2,10). El modelo demostró una alta capacidad de adaptación para capturar tanto las situaciones de estancamiento por fricción burocrática como los picos de uso efectivo. Asimismo, la provisión de Intervalos de Alta Densidad (HDI) al 94% otorgó un rango de probabilidad real sobre la tasa de adopción, alcanzando un sólido rango de 27,0% a 30,2% en el escenario de éxito, lo cual supera la limitación de los reportes frecuentistas puntuales y permite planificar los recursos de soporte sobre bases certeras.

Finalmente, los resultados cuantitativos convalidan que el éxito del Proyecto IGT está directamente ligado a las políticas activas de acompañamiento institucional. La telemetría evidenció un quiebre estructural positivo e inmediato tras la formación de los operadores jurídicos, consolidando a la programación probabilística como una herramienta clave para el diseño, evaluación y optimización de políticas públicas eficientes e informadas.

Bibliografía

- Blei, D. M., Kucukelbir, A., & McAuliffe, J. D. (2017). *Variational Inference: A Review for Statisticians*. Journal of the American Statistical Association, 112(518), 859-877.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3rd ed.). CRC Press.
- McElreath, R. (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan* (2nd ed.). CRC Press.
- Salvatier, J., Wiecki, T. V., & Fonnesbeck, C. (2016). *Probabilistic programming in Python using PyMC3*. PeerJ Computer Science, 2, e55.
- Documentación interna y planificación técnica del Proyecto IGT, Función Judicial de La Rioja (2026).
- Material y apuntes teóricos de la cátedra "Estimación Bayesiana" (2026). Licenciatura en Análisis y Gestión de Datos, Universidad Nacional de San Luis. Equipo docente: Fernández Elina y Garay Pablo.